

## Sprawozdanie z projektu:

### Wykrywanie naczyń dna siatkówki oka

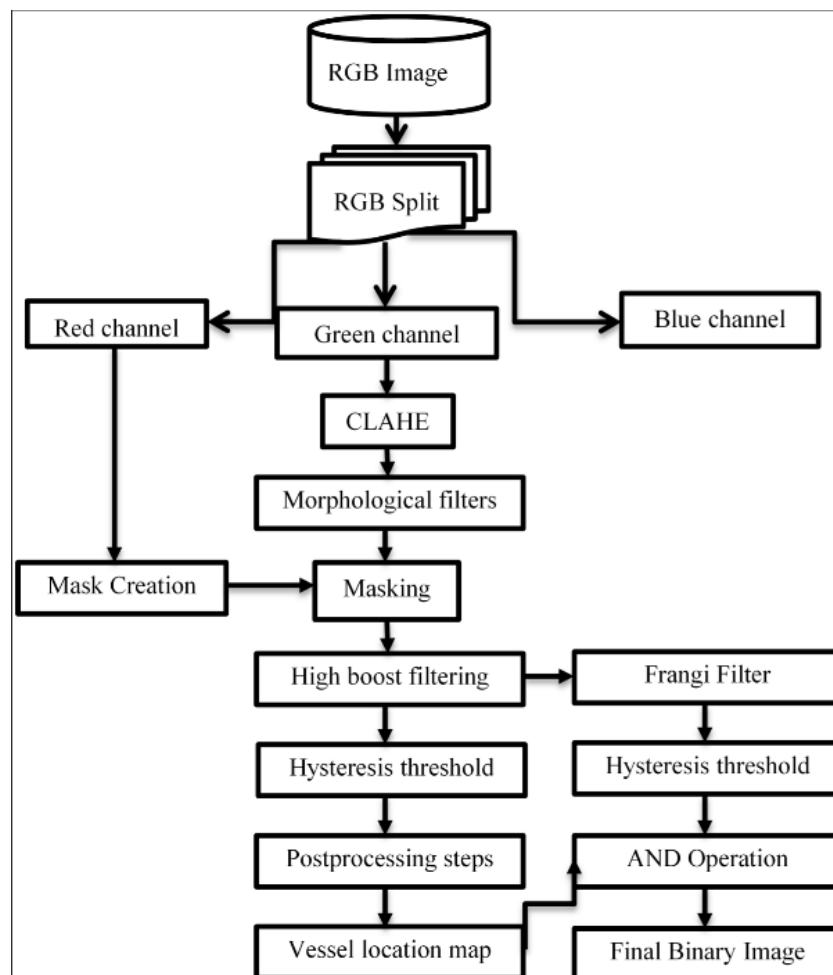
#### 1. Zastosowane technologie:

Kod projektu został w całości stworzony w Pythonie. Dodatkowo wykorzystywane były biblioteki: opencv, numpy, matplotlib, skimage, os i errno, a do korzystania z sieci neuronowej: tensorflow oraz keras

#### 2. Opis zastosowanych metod:

##### 2.1. techniki przetwarzania obrazu

Idea wykorzystana w algorytmie:



Przebieg działania algorytmu:

1. Wyodrębnienie kanału zielonego (zapewnia on najlepsze rozróżnienie naczyń od tła)
2. Normalizacja histogramu (wyostrzenie różnic w obrazie, metoda CLAHE)
3. Erozja i dylatacja (usunięcie szumu tła, zwiększenie czytelności obrazu)
4. Usunięcie tła obrazu

5. Ponowna normalizacja histogramu
6. Usunięcie pozostałych szumów
7. Progowanie (thresholding), stworzenie maski binarnej

## 2.2. Sieć neuronowa

Zastosowana została głęboka sieć neuronowa UNet, ucząca się na danych w postaci całych obrazów naczyń dna siatkówki oka oraz ręcznie sporządzonych masek binarnych ukazujących przebieg naczyń.

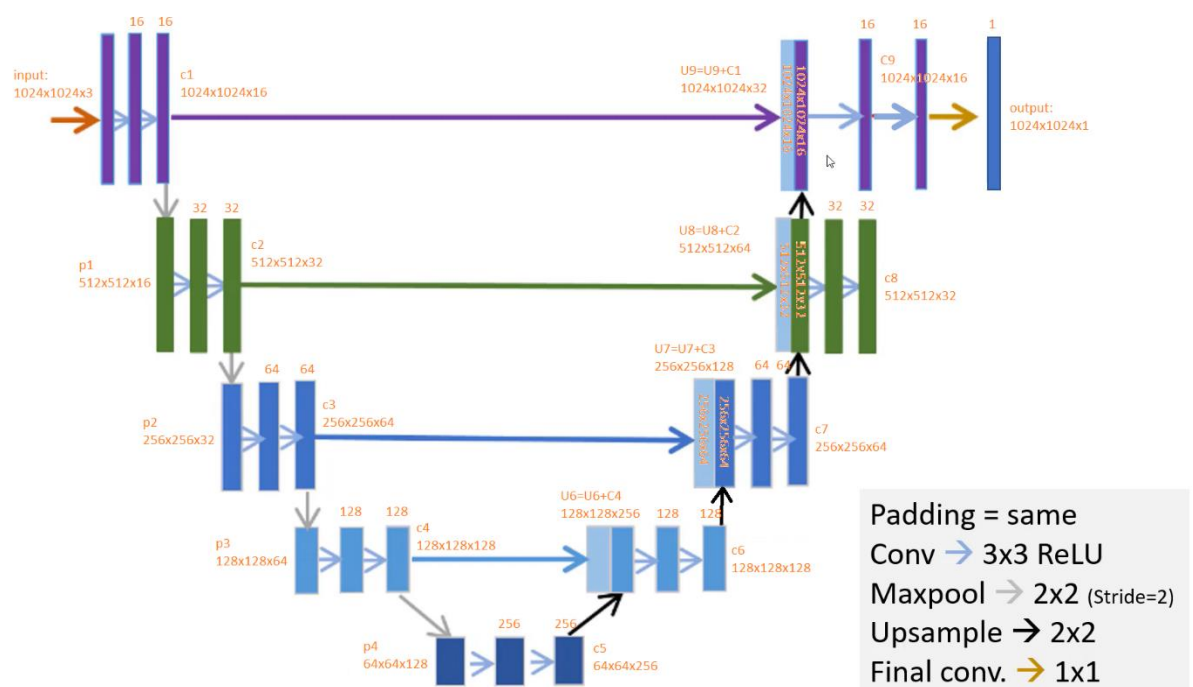
W projekcie został wykorzystany zbiór danych CHASE, składający się z obrazu oraz jego maski.

Podział zbioru:

- Zbiór trenujący zawiera 21 obrazy.
- Zbiór walidujący składa się z 2 obrazów.
- Zbiór testowy to 5 obrazów.

Obraz wejściowy jest skalowany do wymiarów: 1024x1024

Budowa sieci:



Parametry sieci neuronowej:

- Wielkość próbki (batch size): 2
- Liczba epok (epochs): 100 (przy 61 epoce sieć zakończyła dalsze uczenie z powodu braku istotnej poprawy na zbiorze walidującym w ciągu ostatnich 5 epok)
- Wyniki nauki sieci neuronowej:

Zbiór trenujący

1. loss: 0.0764
2. accuracy: 0.9704

Zbiór walidacyjny:


1. val\_loss: 0.1000
2. val\_accuracy: 0.9635

### 3. Wizualizacja działania

#### 3.1. techniki przetwarzania obrazu

Notacja układu obrazów: obraz wejściowy -> obraz wyjściowy -> idealna maska

1)



	True Positive	True Negative
Predicted Positive	36497	22339
Predicted Negative	22874	877330




accuracy: 0.9529

sensitivity: 0.6147

specificity: 0.9752

geometric mean: 0.7743

2)



	True Positive	True Negative
Predicted Positive	41236	32971
Predicted Negative	9883	874950



accuracy: 0.9553

sensitivity: 0.8067

specificity: 0.9637

geometric mean: 0.8817

3)




	True Positive	True Negative
Predicted Positive	44462	20836
Predicted Negative	26029	867713

accuracy: 0.9511

sensitivity: 0.6307  
specificity: 0.9766  
geometric mean: 0.7848


4)



	True Positive	True Negative
Predicted Positive	32006	14078
Predicted Negative	26978	885978

accuracy: 0.9572  
sensitivity: 0.5426  
specificity: 0.9844  
geometric mean: 0.7308

5)



	True Positive	True Negative
Predicted Positive	26050	9305
Predicted Negative	30059	893626

accuracy: 0.9590

sensitivity: 0.4643


specificity: 0.9897

geometric mean: 0.6779

### 3.2. sieć neuronowa

Notacja układu obrazów: obraz wejściowy -> obraz wyjściowy -> idealna maska

1)



	True Positive	True Negative
Predicted Positive	70336	43771
Predicted Negative	12054	922415


accuracy: 0.9468

sensitivity: 0.8537

specificity: 0.9547

geometric mean: 0.9028

2)



	True Positive	True Negative
Predicted Positive	60318	24934
Predicted Negative	9781	953543


accuracy: 0.9669

sensitivity: 0.8605

specificity: 0.9745

geometric mean: 0.9157

3)





	True Positive	True Negative
Predicted Positive	85369	37535
Predicted Negative	9972	915700



accuracy: 0.9547  
sensitivity: 0.8954  
specificity: 0.9606  
geometric mean: 0.9274



4)



	True Positive	True Negative
Predicted Positive	64970	24775
Predicted Negative	14003	944828

accuracy: 0.9630  
sensitivity: 0.8227  
specificity: 0.9744  
geometric mean: 0.8954

5)





	True Positive	True Negative
Predicted Positive	63450	32273
Predicted Negative	10244	942609

accuracy: 0.9595

sensitivity: 0.8610

specificity: 0.9669


geometric mean: 0.9124

#### 4. Analiza wyników

Porównanie podejścia przetwarzania obrazu oraz podejścia sieci neuronowej:

image:		image processing:	neural network:
1	accuracy	0.9529	0.9468
	sensitivity	0.6147	0.8537
	specificity	0.9752	0.9547
	geometric mean	0.7743	0.9028
2	accuracy	0.9553	0.9669
	sensitivity	0.8067	0.8605
	specificity	0.9637	0.9745
	geometric mean	0.8817	0.9157
3	accuracy	0.9511	0.9547
	sensitivity	0.6307	0.8906
	specificity	0.9766	0.9606
	geometric mean	0.7848	0.9274
4	accuracy	0.9572	0.9630
	sensitivity	0.5426	0.8227
	specificity	0.9844	0.9744
	geometric mean	0.7308	0.8954
5	accuracy	0.9590	0.9595
	sensitivity	0.4643	0.8610
	specificity	0.9897	0.9669
	geometric mean	0.6779	0.9124

Notacja układu: obraz wejściowy -> obraz wyjściowy z przetwarzania obrazu -> obraz wyjściowy z sieci neuronowej -> idealna maska



Na podstawie danych statystycznych i wizualnych możemy jednoznacznie stwierdzić, że sieć neuronowa poradziła sobie z problemem znacznie lepiej. Jest to szczególnie widocznie w przypadku czułości oraz miar bardziej odpornych na niebalansowane klasy decyzyjne, tj. średnia geometryczna czułości i swoistości.